

Utilize LLM Resiliency for Efficient Memory Sub-systems

Jinwoo Jeong

(Hanyang University, South Korea)

jwjeong@hanyang.ac.kr

2026.02.28


Research Objective

- Broad Research Aim
 - Efficient NAND Flash based LLM Inference System
 - LLM weight의 bit error resilience와 unary protection의 효과 분석
- Key Milestones
- Weekly Focus
 - Element wise의 unary encoding 적용 방식에 대한 고찰

Prior Discussion

- Main Takeaways from Last Meeting

- 페이지 별 다른 종류의 값을 할당하는 방식이 왜 Accuracy 개선에 도움이 되는지에 대한 소명
 - Page 별 다른 종류의 값을 할당하는 방식이 accuracy 개선에 도움이 되는 이유
 - Flash memory의 내구성 차이 특성은 최소 page 단위로 차등화 가능함 (unbalanced gray coded LSB / CSB / MSB page)
 - ECC는 codeword 단위로 equal error protection을 수행함 -> ECC decoding 이후 codeword 내 모든 비트의 error probability가 동일
 - Sensitivity diversity를 무시하고 데이터를 저장하면 **가장 sensitivity가 높은 bit-plane 혹은 weight**를 기준으로 ECC margin을 설정해야 함



- IFP 상황에서 LSB Page에 Sensitive data를 할당해야 하는 이유
 - 이전 논의에서 bit-plane level sensitivity를 분석하여 unary+binary 표현의 가능성을 탐색할 때, MSB (sign)나 SMSB bit의 무결성이 보장되어야 함 (실험 세팅에서는 error masking을 의미함)
 - Error mask는 ECC를 강화하는 것보다 RBER을 낮추는 것이 훨씬 비용 효율적 (Appendix A)

	Masked Error Injection(Avg. PPL)					
Repr. type	sign-magnitude					
Group size	per-ch (4K)			32		
Error mask	No mask	MSB	SMSB	No mask	MSB	SMSB
no-error	6.116			5.65		
1.00E-02	287.291	33.03	14.67	7.9896	6.23	6.86

Proposal




- Approach – Unary code를 어떻게 적용할 것인가?
 - Unary encoding 길이에 따라 space overhead가 큼 (n bits $\rightarrow 2^n - 1$ bits)
 - Quantization group 단위 sensitivity ranking을 기반으로 차등적인 unary level 적용
 - ex) int6 RTN을 가정할 때, L1 = binary only, L2 = u2b4, L3 = u3b3, ... L6 = u6b0 (full-unary) 를 적용
 - 각 level의 비중을 결정하기 위해 점진적이며 greedy한 방식으로 탐색을 수행
 - Full unary로 인코딩 된 모델에서 partial unary로 인코딩 되는 영역을 점진적으로 늘리면서 accuracy 유지 가능한 차등적인 unary level 비율 탐색
- Rationale or Intuition
 - Unary code를 적용하는 방식
 - 1) bit plane sensitivity diversity를 고려하여 모든 weight의 MSB를 일괄적으로 보호
 - 2) weight element-wise로 sensitivity diversity를 판별하여 중요 weight를 따로 보호 <- **weekly focus**
 - Quantized weight는 Quantization group 마다 고유의 dynamic range를 갖게됨
 - Weight Group 단위로 sensitivity를 정의 (Appendix B)
 - $Sense = Scale * \sum H \rightarrow Sense = Sensitivity$, H =weight element에 대응하는 hessian
 - 소수의 Sensitive weight에 max level의 unary를 적용하고, robust할수록 낮은 level을 적용하면 space overhead를 최소화할 수 있음

Results

- Progress to Date

- Multi-level unary encoding이 필요한 이유

- Figure 1은 unary level을 2개만 설정하여, full-unary or binary로만 저장하는 상황을 시뮬레이션
 - ex) Selective unary encoding ratio (selective_pct)=20
-> top-20% sensitive weight group=full-unary, 나머지는 binary (unsigned int)
 - Selective pct를 늘릴수록 resiliency가 개선되는 것을 확인
 - 하지만, 1e-2 수준의 높은 BER에서는 binary 영역이 20%만 넘어도 accuracy가 크게 저하되는 것을 확인
 - 이는 no-protection으로 1e-2까지 버틸 수 있는 robust-weight의 비중이 생각보다 작은 것을 시사하며, 차등화를 통한 Space overhead 완화 효과가 작음



Results




- Progress to Date

- Multi-level unary encoding

- opt-125m (left), opt-1.3b (center), opt-6.7b (right)에 대해서 accuracy 유지가 가능한 level 별 range를 탐색한 결과 (optimal 아님)
 - {u=0: L1, u=2: L2, ... u=6: L6} 여기서 u는 6-bit int weight의 상위 몇 비트를 unary encoding 했는지를 의미함

- Summary

- 모델 크기가 커질수록 binary를 많이 포함시켜도 accuracy 유지력이 좋으며 full unary가 필요한 sensitive weight가 감소
 - opt-1.3b의 경우, 2 level 구성과 비교할 때, space overhead 10.5 -> 2.917로 크게 감소
 - opt-6.7b는 space overhead x1.55 수준으로 요구성능 달성 가능




Discussion

- Interpretation of Findings
 - Unary encoding을 level을 세분화하여 적용하는 것은 resiliency를 높이면서 space overhead를 크게 완화
 - Bit-plane-level로 unary를 일괄 적용하는 방식은 binary로 저장해도 되는 가중치까지도 space overhead가 발생하기 때문에 sub-optimal
 - 현재 sensitivity 기반 탐색 방법은 greedy한 방식이기도 하고, 전체 weight space에서 unary level 별 범위를 조정하면 모두 탐색하기 때문에 더 큰 모델에서 적용 어려움
 - 다만 "Unary coding을 어떻게 적용해야 할까?" 에 대한 큰 방향성은 대략적으로 다음과 같음
 - 1) Robust weight group을 우선적으로 식별하여 search space에서 제거
 - 2) Sensitive group내 weight의 Sensitive bit plane 식별하여 high-reliable region에 저장 (LSB page 혹은 SLC buffer)
 - 3) 남은 Sensitive weight에 대해 group 단위 multi unary level mapping
- Next Steps
 - Sensitive group 식별을 빠르고 정확하게 수행하기 위해선, sensitivity threshold value가 정량적으로 설정 가능해야 함
 - 현재 OPT-6.7b 모델에 대한 multi-level range searching 은 약 7시간 이상 소요됨
 - Layer output MSE 와 Sensitivity + BER의 상관관계를 파악하여 정량화 가능성 파악 예정


Appendix A

- Lightweight ECC 특성과 한계




Appendix B

- Weight Element-wise / Group-wise Sensitivity



- 각 row와 column을 scale 혹은 H_{inv} 의 내림차순으로 정렬하면 아래의 그림과 같은 sensitivity를 볼 수 있음
- 왼쪽의 scale과 input activation을 크기에 따른 내림차순으로 정렬할 때, 소수의 column 혹은 row 만 (~1%) 크기가 큰 activation이나 scale을 보임



즉, weight group 별로 bit flip으로 인한 output 변화 기여도가 다른 이는 group 단위로 차등적인 protection level이 필요함을 시사함